IMAGE FORENSICS · DEFENSE

图像篡改检测与定位

一个骨干给出真伪、类型与区域，压缩转发后仍可用。

只看真伪，不够支撑处置。

反诈审核的真实需求

一张转账截图被判定"疑似伪造"之后，审核员还要回答三个问题。

01 改的是金额区域，还是整块拼接了别人的凭证?

02 这是拼接、复制移动，还是 AI 生成?

03 图经过微信转发，模型还能不能信?

THREE FRICTIONS

难点不在模型大小，而在分布与部署

FRICTION 01

来源不一致

CASIA、TIGAS 与合成样本的压缩历史、分辨率、噪声分布不同，模型容易学到数据集的捷径。

DATA DISTRIBUTION

FRICTION 02

任务相互牵制

只训二分类会丢掉类型信息；只训分割又缺少图级判断。三个任务需要共享同一套证据。

MULTI-TASK

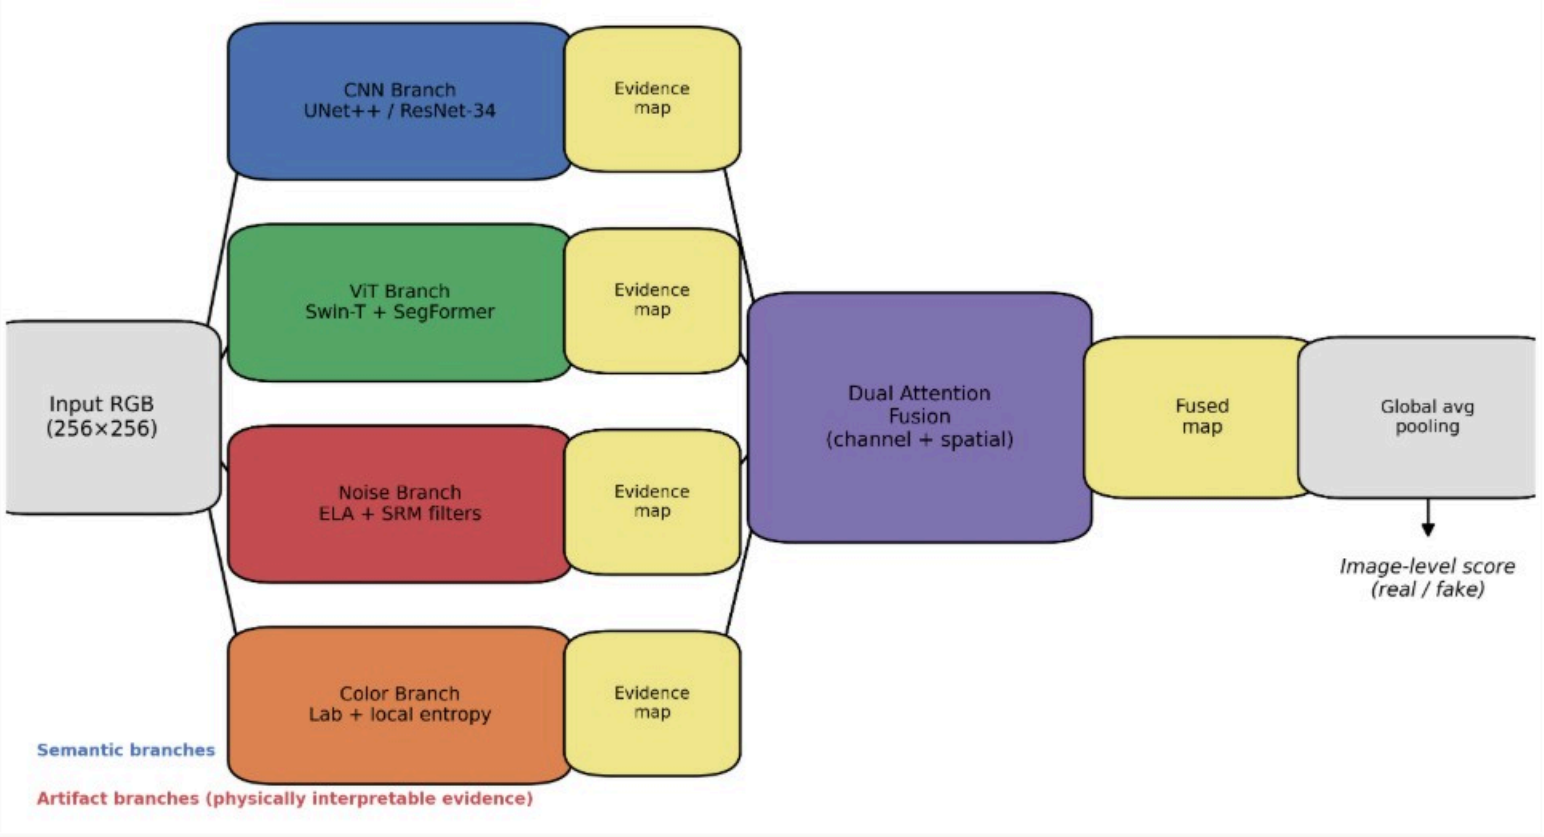
FRICTION 03

部署条件苛刻

真实案件图片普遍经过 JPEG 压缩、缩放甚至截图，干净验证集上的高分并不等于可用。

ROBUSTNESS

四支证据
一次判决



CNN 与 ViT 提供语义证据，ELA/SRM 与 Lab 熵提供物理证据；融合图同时给出图级分数和像素级定位。v3.0 将 ViT 分支替换为 DINOv2 ViT-L/14（448×448）。

BRANCHES

4

语义 + 物理证据

INPUT

448

DINOv2 patch 对齐

OUTPUTS

3

真伪 · 类型 · 区域

PURE CASIA VALIDATION · 2,866

类型与定位达到可用线

相比 ep5：类型 F1 +13.1，定位 mIoU +27.1（TTA）。

256px 小骨干：F1 0.818→0.849，mIoU 0.490→0.603；AUC 0.977→0.969。



TYPE F1 OVER EPOCHS

类型与定位同步收敛

EP 05	0.718	类型 F1 起点
EP 10	0.802	多任务开始收敛
EP 14	0.825	EMA 首次反超
EP 20	0.849	分类最佳
EP 30	0.839	分割 0.603（TTA）

READING

类型与定位同步提升，说明共享证据能同时服务分类与定位，而不是此消彼长。

OVERSHOOT

30 轮后类型指标回落，混合分布上开始过拟合。

DEPLOY

分类取 ep20 EMA，分割取 ep30。

AUC AFTER JPEG / RESIZE / BLUR

压缩增强后，q90 的 AUC 到 0.89



CLEAN

原始指标基本不变：F1 0.839→0.841，mIoU 0.584→0.584

GAIN

模糊条件类型 F1 +34.9 点；缩放 AUC +15 点

COPY RECALL

q90 从 28.8% 提升到 41.1%，仍是弱项

训练时以 50% 概率施加 JPEG(q50–95)、缩放(0.5–1.0) 与高斯模糊，并重算 ELA 与熵图。数据：同一 CASIA 验证集。

BORROWED FROM CLAUDE

五档能力映射

Haiku · 级联快筛 01

3–19 ms 初筛，低置信再升级全模型。

Sonnet · last_ema 02

均衡默认档，clean 与鲁棒性兼顾。

Opus · ep30_raw 03

clean 上限最高，用于离线复核与基准。

Fable · ep20_ema 04

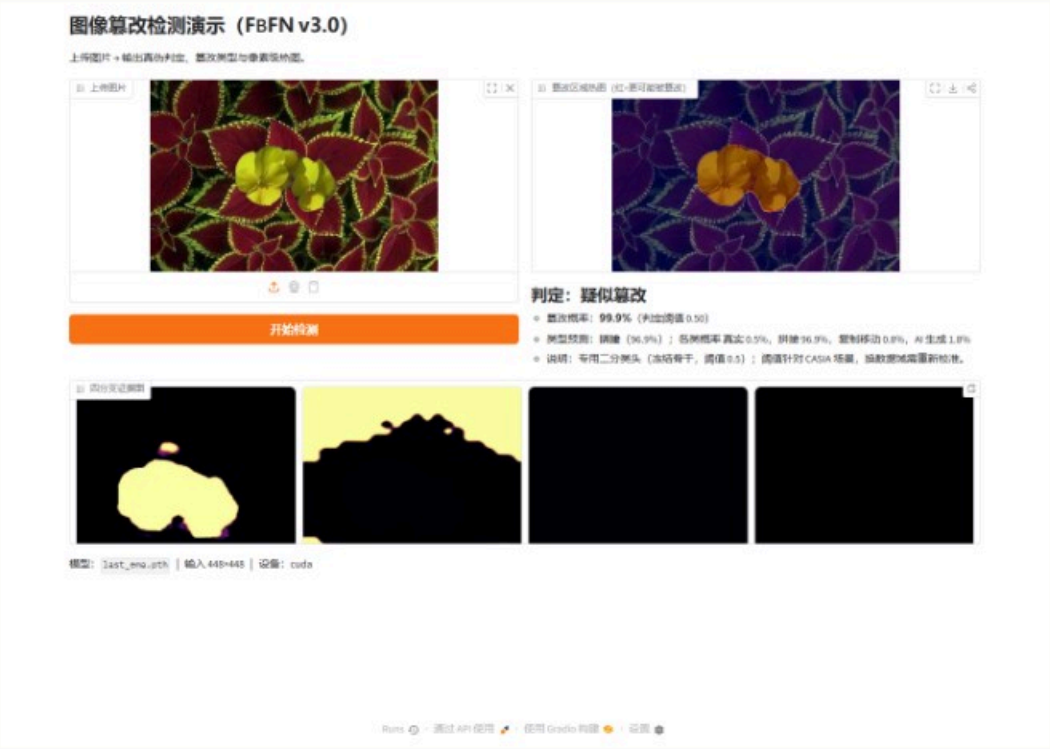
最擅长讲清篡改类型，F1 0.849。

Mythos · FBFN v3.0 05

四支证据 + 多任务 + 鲁棒部署的完整系统。

只是类比 NOTE

五档同源，区别在用途与工作点，不是模型规模。



Gradio 单页应用，本机 5060 或 A40 服务器（bf16，端到端 81 ms）；上传后同时给出真伪概率、类型分布、热图与四分支证据图。

TAMPER PROB

99.9%

专用头 · 阈值 0.5

SPLICE

96.9%

类型预测

MODEL

last_ema

448 px · 鲁棒版

WHERE IT STILL FAILS

边界清晰，低置信交给人工

拼接 · 可直接用 01

召回 82–86%，精确率约 90%，大区域拼接最稳。

复制移动 · 需复核 02

召回约 76%，小区域和相似纹理容易漏。

截图 · 低置信 03

AUC 0.78、定位 mIoU 0.20，建议转人工。

GAN · 非主场景 04

BigGAN 接近随机，模型主要针对扩散生成。

新生成器 · 待补数据 05

未见家族 AUC 66–77%，需持续扩充训练集。

产品策略 06

把"低置信"当作一等公民：输出置信度与热图，让人工复核有依据。

MANIFESTO

可解释，可部署。

一个骨干统一三个任务；压缩增强保证真实转发图可用；低置信可以识别并转人工。

01 **统一三任务**

共享证据特征，一次推理给出真伪、类型与区域。

02 **压缩后仍可用**

增强训练让 q90 AUC 从 0.85 到 0.89，clean 基本无损。

03 **低置信可识别**

阈值与温度校准，输出可复核的置信度与热图。

GITHUB.COM/CHANGEST/IMAGE-TAMPERING-DETECTION-3.0