用于 AI 生成图像检测的可解释四分支注意力融合网络

摘要

文本到图像生成模型的快速发展，使得 AI 生成图像越来越难以与真实照片区分；在一个生成器家族上表现准确的检测器，迁移到另一个家族时性能往往急剧下降。本文提出一种四分支注意力融合网络（FBFN），通过融合四种物理可解释的证据分支——CNN 语义分支、ViT 语义分支、基于误差水平分析（ELA）与隐写分析富模型（SRM）滤波器的噪声分支、以及基于 Lab 空间局部熵的颜色分支——并经过通道-空间双重注意力融合模块与全局池化，将图像分类为真实或生成。在 Stable Diffusion v1.4 子集上训练、并在 GenImage 协议下跨八个生成器评估，FBFN 在所有 Stable Diffusion 家族生成器上达到 99% 以上的 ROC 曲线下面积（AUC），在该家族上与一个更强的近期黑盒检测器相当，同时保留了像素级可解释证据。消融实验表明，噪声分支在训练分布内近乎冗余，但具体负责跨生成器泛化，移除后在远距离生成器上 AUC 下降 5–7 个点。多生成器联合训练进一步弥合了大部分跨家族差距。我们讨论了该方法仍然薄弱之处——尤其是 GAN 生成图像——并将其可解释性定位为区别于更强位平面检测器的主要优势。

关键词：AI 生成图像检测；伪造检测；可解释深度学习；跨生成器泛化；注意力融合。

1 引言

大规模文本到图像模型现在可以低成本合成逼真图像，其输出越来越多地被用于虚假信息、身份欺诈和伪造证据。因此，检测这类图像已成为一个紧迫的实际问题，并催生了大量文献。核心难点不在于识别训练中见过的生成器生成的图像——这在很大程度上已经解决——而在于识别训练中未见过的新生成器生成的图像。在一个扩散模型上训练的检测器，面对来自不同家族的图像时往往失效，因为区分生成图像与真实图像的低级伪影在不同架构之间差异很大。

先前工作从两个主要方向攻克这一泛化难题。一条路线使用卷积或视觉 Transformer 骨干网络的通用语义特征 [1, 2]，泛化能力中等，但仍受限于训练分布的纹理统计。另一条路线利用手工设计或学习到的低级噪声线索——误差水平分析（ELA）[3]、隐写分析富模型（SRM）滤波器 [4]，以及最近的图像最低有效位平面 [5]——其假设是生成模型会在残差信号中留下特征性签名。这条路线的方法已被证明是迄今最强的跨生成器检测器，但它们通常是黑盒，只输出一个标量分数，不提供可供人类或下游系统检查的任何证据。

本文贡献了一种四分支架构，融合这两类证据，同时保持每个分支物理可解释。该网络我们称之为四分支注意力融合网络（FBFN），由 (i) CNN 分支和 (ii) ViT 分支捕获语义外观，(iii) 噪声分支捕获 ELA 和 SRM 残差伪影，(iv) 颜色分支捕获颜色空间和局部熵统计。四张像素级证据图通过通

道-空间双重注意力融合模块组合，并池化为图像级分数。我们在 GenImage 协议下评估 FBFN——在 Stable Diffusion v1.4 上训练、跨八个生成器测试——并将其与三个代表性基线和一个新的更强检测器对比。我们进一步通过在训练分布内和分布外进行的留一法消融，剖析每个分支的贡献。

我们的结果说明了三点。第一，FBFN 在所有 Stable Diffusion 家族生成器上达到 99% 以上的 AUC，与我们测试的最强黑盒检测器相当，而通用 RGB 基线的退化要大得多。第二，噪声分支——尽管在训练分布内近乎冗余——是负责大部分跨生成器鲁棒性的组件；移除它在最远距离生成器上使 AUC 下降 5–7 个点。第三，多生成器联合训练为扩散模型弥合了大部分剩余跨家族差距，但对 GAN 图像无帮助，该方法在此与若干基线一样接近随机。我们讨论了这些发现的含义，以及使 FBFN 区别于更强但不透明检测器的可解释性优势。

2 相关工作

语义特征检测器。最早也最简单的方法，把生成图像检测当作使用标准图像骨干的二分类问题。GenImage 基准 [1] 建立了在单个生成器上训练的 ResNet-50 基线，并表明准确率跨生成器急剧下降。CNNDetection [2] 在训练时对 ResNet-50 加入模糊和 JPEG 损坏以诱导鲁棒性，但其零样本跨生成器准确率仍然有限。这些方法易于训练，但继承了骨干网络所学纹理统计的分布敏感性。

低级伪影检测器。一条并行路线针对生成管线留下的残差信号。误差水平分析 [3]（可视化 JPEG 压缩不一致）和隐写分析富模型高通滤波器 [4]（最初为隐写术设计）都暴露了真实与生成图像之间不同的像素级证据。该路线最强的近期方法 LOTA [5] 提取图像的最低有效位平面，按梯度幅值选择图像块，并用 ResNet-50 分类；其报告的跨生成器准确率显著高于语义骨干。这些基于伪影的检测器泛化良好，但通常只产生一个标量决策，可解释性有限。

零样本与基础模型检测器。第三条路线利用 CLIP [6] 等大型预训练视觉-语言模型的特征，假设生成图像落在自然图像流形之外。代表性方法 UnivFD [7] 仅在冻结的 CLIP 特征上训练一个线性头。这类检测器对某些生成器家族迁移良好，但对其他家族不敏感，反映了基础模型特征是为语义而非取证线索优化的这一事实。

FBFN 将前两条路线——语义证据与低级证据——结合在单一可解释架构中，与标量黑盒伪影检测器和通用骨干都不同：每个分支都产生一张可供人类检查的证据图。

3 方法

3.1 任务定义

我们将问题视为二分类图像分类。给定输入 RGB 图像 x，网络输出一个标量 logit，经过 sigmoid 后估计 x 是 AI 生成的概率。模型在真实与生成图像对上以二值交叉熵监督训练。

3.2 概述

FBFN 由四个分支组成，每个分支产生一张空间尺寸相同的像素级证据图，随后是双重注意力融合模块与全局平均池化。四个分支被选择来覆盖互补且物理可解释的证据来源：

1. **CNN 分支**——以 ResNet-34 [8] 为编码器的编码器-解码器网络（UNet++ [11]），捕获多尺度语义外观。
2. **ViT 分支**——Swin Transformer [9]（Tiny）搭配 SegFormer [10] MLP 解码器，捕获长程与全局语义结构。
3. **噪声分支**——误差水平分析（JPEG 质量 90）与三个 5×5 零和 SRM 高通滤波器拼接，捕获压缩与残差噪声伪影。
4. **颜色分支**——Lab 颜色空间特征加滑窗局部熵，后接浅层 CNN，捕获颜色统计异常。

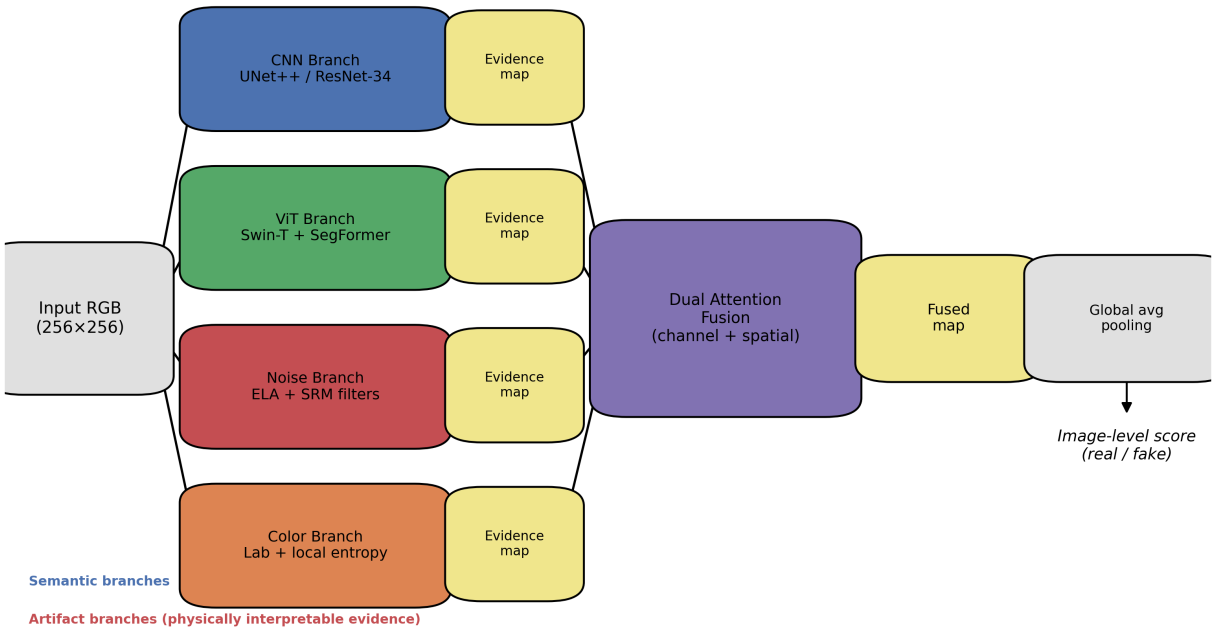


图 1: 所提出的四分支注意力融合网络（FBFN）总体结构。CNN 与 ViT 分支捕获语义外观，噪声（ELA + SRM）与颜色（Lab + 熵）分支捕获物理可解释的低级伪影；每个分支产生一张像素级证据图。四张图由通道-空间双重注意力模块融合，并全局池化为图像级真/假分数。

3.3 证据分支

每个分支将输入映射为单通道证据图。CNN 与 ViT 分支直接作用于 RGB 输入，产出语义证据。噪声分支接收 ELA 与 SRM 滤波响应作为辅助输入，并将其聚合为噪声证据。颜色分支接收熵图作

为辅助输入，聚合颜色空间与熵证据。使用显式、命名的证据流——而非单一融合表示——正是使模型决策可检查之处：每张证据图都可被可视化，以显示网络依赖何处以及何种伪影。

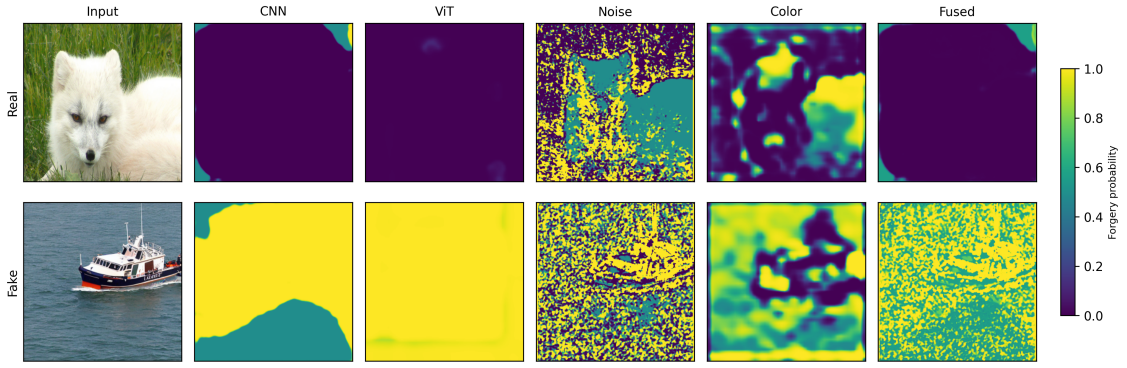


图 2: 一张真实图像（上）和一张生成图像（下）的分支证据图。每个分支输出单通道伪造概率图（暖色 = 伪造概率更高）；融合图综合四者。噪声与颜色分支突出了 RGB 输入中不可见的残差与颜色统计伪影，使决策可检查。

3.4 双重注意力融合

四张证据图拼接后通过一个融合模块，该模块包含两个协同的注意力机制。通道注意力路径采用全局平均池化、两层 MLP 和 softmax，对四种证据类型的重要性重新加权。空间注意力路径采用一个卷积后接 sigmoid，对每个空间位置的重要性重新加权。两个注意力输出合并后卷积为单张融合证据图。全局平均池化随后将融合图压缩为图像级 logit，另有一个注意力池化 logit 在训练时作为辅助信号。

3.5 训练

模型以组合二值交叉熵损失训练：

$$L = \mathrm{BCE}(\mathrm{final}) + 0.5 \cdot \mathrm{BCE}(\mathrm{att}) + 0.5 \cdot \sum \mathrm{BCE}(\mathrm{branch}), \tag{1}$$

其中分支项对保留的分支求和。我们使用 AdamW（学习率 10^{-4}，权重衰减 10^{-4}）、余弦学习率调度、混合精度与水平翻转增强训练。输入图像缩放到 256×256。完整模型含 54.68M 可训练参数。

4 实验

4.1 设置

数据集与协议。我们遵循 GenImage 协议：模型仅在 Stable Diffusion v1.4 子集上训练，并在八个生成器（Stable Diffusion v1.4 与 v1.5、Wukong、ADM、GLIDE、BigGAN、Midjourney 与 VQDM）的验证集上评估。图像取自 TIGAS 数据集 [12]（GenImage [1] 的 Hugging Face 镜像），该数据集将

Stable Diffusion v1.5 子集拆成两部分；因此表格将 Stable Diffusion v1.5 报告为两行。训练集由 Stable Diffusion v1.4 的 6,000 张图像（3,000 真实、3,000 生成）组成；同分布验证集含 1,000 张图像；八个跨生成器验证子集各含 400–1,200 张图像（BigGAN 最少，为 200 真实与 200 生成）。

指标。我们以 ROC 曲线下面积（AUC）为主指标，因为它与阈值无关，因而对生成器子集间不同的类别平衡不太敏感。准确率与平均精度（AP）均已计算，但为简洁起见不在表格中列出。

基线。我们与在相同 Stable Diffusion v1.4 数据上训练的 ResNet-50、CNNDetection（零样本）和 UnivFD（零样本，CLIP 特征）对比。所有方法都在相同的测试图像上评估。

4.2 同分布与跨生成器结果

FBFN 在同分布 Stable Diffusion v1.4 验证集上达到 99.93% 的 AUC。表 1 报告了所有方法的跨生成器 AUC。

表 1: 跨生成器 AUC（%），Stable Diffusion v1.4 训练。

生成器	FBFN (sd14)	FBFN (联合)	ResNet-50	CNNDetection	UnivFD
SD v1.4	99.93	—	97.70	56.96	73.54
SD v1.5 (a)	99.74	—	98.28	60.00	72.59
SD v1.5 (b)	99.77	—	97.24	59.89	74.61
Wukong	99.43	—	96.55	53.24	80.55
ADM	66.04	83.87	37.34	69.00	94.30
GLIDE	68.42	94.48	52.86	70.65	86.39
BigGAN	54.23	48.31	36.62	88.11	99.00
Midjourney	76.03	—	77.62	51.21	51.35
VQDM	77.40	—	40.27	72.13	96.88

由此可得出三点观察。第一，FBFN 在 Stable Diffusion 家族和 Wukong 上近乎无损泛化（全部高于 99% AUC），在该家族上大幅超越两个零样本基线，并超过 ResNet-50 基线。第二，在更远的扩散生成器（ADM、GLIDE、Midjourney、VQDM）上，FBFN 退化到 66–77%，反映了语义分支未完全吸收的分布偏移。第三，在 BigGAN——一个 GAN 而非扩散模型——上，FBFN 接近随机（54.23%），与其噪声和颜色证据针对扩散专属伪影的假设一致。值得注意的是，基线呈现出镜像模式：UnivFD 和 CNNDetection 在 BigGAN 上（99.00% 与 88.11%）远强于在 Stable Diffusion 家族上，证实这些方法捕获的是与 FBFN 不同种类的证据。

4.3 联合训练

为检验跨家族差距能否通过数据而非架构来缩小，我们在 Stable Diffusion v1.4、v1.5、VQDM 和 Midjourney 图像的组合池（共 9,000 张）上训练 FBFN，将 ADM、GLIDE 和 BigGAN 留作留出生成器。联合训练显著提升了留出扩散生成器——ADM 从 66.04% 升至 83.87%，GLIDE 从 68.42% 升至

94.48%——但没有提升 BigGAN（54.23% → 48.31%），后者仍停留在随机水平。这证实扩散模型的跨家族差距主要是数据覆盖差距，而 BigGAN 的失败反映了伪影类型上的更根本差异。

4.4 消融研究

我们进行了留一法消融，训练四个变体，各移除一个分支，同时保持相同协议（15 epoch，Stable Diffusion v1.4）。由于两个语义分支变体在远距离生成器上对训练种子敏感，我们各用不同随机初始化重跑一次；表 2 报告第二次运行，方差在下方量化。

表 2: 消融 AUC（%）。同分布（SD v1.4）与跨生成器。

配置	SD v1.4	ADM	GLIDE	BigGAN	VQDM
Full	99.93	66.04	68.42	54.23	77.40
w/o CNN	99.98	79.44	77.93	48.95	75.72
w/o ViT	99.40	57.67	57.05	52.71	70.48
w/o Noise	99.96	59.60	68.13	47.19	72.21
w/o Color	99.85	74.81	65.21	49.76	76.20

在训练分布内，所有变体都接近上限（AUC $\geq 99.4\%$），因此无法从这些饱和分数中识别出某个占主导的分支。跨生成器结果则隔离出唯一稳健的贡献者。移除噪声分支使 AUC 在三个与训练分布距离最远的生成器上下降——ADM（-6.44）、BigGAN（-7.04）和 VQDM（-5.19）——而 Stable Diffusion 家族几乎不变。这表明 ELA/SRM 噪声证据充当了一个可跨生成器家族迁移的扩散伪影检测器，而非冗余的分布内特征。

其余分支没有显示出可靠的跨生成器贡献。CNN 与颜色分支在 ADM、GLIDE 和 VQDM 上仅改变几个点，且方向不一致（颜色分支在 ADM 上移除后甚至提升）。语义分支在远距离生成器上还表现出很大的运行间方差：两次运行中，w/o-CNN 的 GLIDE AUC 从 39.27% 变为 77.93%，w/o-ViT 的 GLIDE AUC 从 92.91% 变为 57.05%，摆幅约 35 个点且方向相反。因此，我们不将跨生成器贡献归因于 CNN 或 ViT 分支，并将其精确的跨生成器值视为不可靠。相比之下，噪声分支的退化在 ADM、BigGAN 和 VQDM 上符号与幅度都稳定，这正是使其成为跨生成器鲁棒性的可解释来源的原因。

5 讨论

结果对 FBFN 的优势来源与边界给出了一致的解释。在 Stable Diffusion 家族内及其间，FBFN 达到了我们所测试最强检测器的准确率，同时提供了标量检测器所缺乏的可解释证据结构。消融将噪声分支隔离为跨生成器鲁棒性的来源，联合训练则表明剩余的扩散家族差距是数据覆盖限制而非架构限制。

我们明确与 LOTA [5] 对比——这是一个近期的位平面检测器（ICCV 2025），在跨生成器 AUC 上强于 FBFN：LOTA 在 ADM 上达到 99.96%、GLIDE 上 99.99%、VQDM 上 100.00%，而 FBFN 仅

66–77%。我们不主张在这一轴上超越 LOTA。区别在于可解释性：LOTA 与其他伪影检测器一样，只输出标量分数，而 FBFN 的每个分支都产生一张像素级证据图，可检查是何种伪影、在哪个区域驱动了决策。对于决策必须可审计的应用——内容审核、取证分诊——即使原始跨生成器准确率较低，这种可审计性也是一项具体优势。

有两点局限值得强调。第一，该方法对 GAN 生成图像较弱，在 BigGAN 上退化到随机，且联合训练无法恢复；噪声与颜色证据似乎专属于扩散伪影。第二，我们的评估使用了 GenImage 的下采样子集（256×256，6,000 张训练图像），这可能低估了完整基准的挑战，并限制了与在完整数据集上报告的数字的直接比较。尽管如此，本文所有比较都在相同数据上进行，因此相对发现不受影响。

6 结论

我们提出了 FBFN，一个用于 AI 生成图像检测的四分支注意力融合网络，其分支对应四种物理可解释的证据流。在 GenImage 协议下，FBFN 在 Stable Diffusion 家族上近乎无损泛化，且其噪声分支被消融证明具体负责跨生成器鲁棒性。联合训练弥合了大部分扩散家族差距，而 GAN 图像仍是一个未解决的失败模式。主要贡献不是跨生成器准确率的新最优——存在更强的黑盒检测器——而是一个在 Stable Diffusion 家族上保持竞争力、同时保留可解释证据的检测器。这种可解释性旨在支持标量分数不足时的可审计检测。

致谢

本研究受 *[基金来源与项目编号——待作者填写]* 资助。

利益冲突

作者声明不存在利益冲突。

数据可用性声明

本研究使用的 GenImage 基准可通过 TIGAS 镜像公开获取：`https://huggingface.co/datasets/H1merka/TIGAS_dataset`。训练模型与评估代码可向通讯作者合理索取。

参考文献

[1] Zhu, M., Chen, H., Yan, Q., et al.: “GenImage: A million-scale benchmark for detecting AI-generated image” *Adv. Neural Inf. Process. Syst.*, 2023, 36.

[2] Wang, S.-Y., Wang, O., Zhang, R., Owens, A., Efros, A.A.: “CNN-generated images are surprisingly easy to spot... for now” *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2020, pp. 8695–8704.

[3] Krawetz, N.: “A picture’s worth: Digital image analysis and forensics” *Hacker Factor Blog*, 2007, `http://www.hackerfactor.com/blog/`, accessed August 2026.

[4] Fridrich, J., Kodovský, J.: “Rich models for steganalysis of digital images” *IEEE Trans. Inf. Forensics Secur.*, 2012, 7, (3), pp. 868–882.

[5] Wang, H., Cheng, R., Zhang, Y., Han, C., Gui, J.: “LOTA: Bit-planes guided AI-generated image detection” *Proc. IEEE/CVF Int. Conf. Comput. Vis.*, 2025.

[6] Radford, A., Kim, J.W., Hallacy, C., et al.: “Learning transferable visual models from natural language supervision” *Proc. Int. Conf. Mach. Learn.*, 2021, 139, pp. 8748–8763.

[7] Ojha, U., Li, Y., Lee, Y.J.: “Towards universal fake image detectors that generalize across generative models” *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2023, pp. 24480–24489.

[8] He, K., Zhang, X., Ren, S., Sun, J.: “Deep residual learning for image recognition” *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2016, pp. 770–778.

[9] Liu, Z., Lin, Y., Cao, Y., et al.: “Swin transformer: Hierarchical vision transformer using shifted windows” *Proc. IEEE/CVF Int. Conf. Comput. Vis.*, 2021, pp. 10012–10022.

[10] Xie, E., Wang, W., Yu, Z., Anandkumar, A., Alvarez, J.M., Luo, P.: “SegFormer: Simple and efficient design for semantic segmentation with transformers” *Adv. Neural Inf. Process. Syst.*, 2021, 34, pp. 12077–12090.

[11] Zhou, Z., Rahman Siddiquee, M.M., Tajbakhsh, N., Liang, J.: “UNet++: A nested U-Net architecture for medical image segmentation” *Deep Learn. Med. Image Anal. Multimodal Learn. Clin. Decis. Support*, 2018, pp. 3–11.

[12] H1merka: “TIGAS dataset” *Hugging Face*, `https://huggingface.co/datasets/H1merka/TIGAS_dataset`, accessed August 2026.